

$$I \in \mathbb{R}^{B \times C_i \times S_i \times S_i}, O \in \mathbb{R}^{B \times C_o \times S_o \times S_o}$$

★ Conv

$$S_o = \left\lfloor \frac{S_i - k + 2 \cdot p}{str} \right\rfloor + 1, \text{ где } k - \text{размер ядра}$$

$p - \text{padding}$
 $str - \text{stride}$

$$\text{FLOPS} = 2 \cdot B \cdot C_i \cdot C_o \cdot S_o^2 \cdot k^2$$

Помним, что память равна весу "весов" и аккумулятору

$$\text{MEM} = C_i \cdot C_o \cdot k^2 + B \cdot C_o \cdot S_o^2$$

★ Max Pool

S_o рассчитывается эквив. CONV

$$\text{FLOPS} = B \cdot C \cdot S_o^2 \cdot (k^2 - 1) \quad \text{т.к. нужно сравн. все эл. по "группам"}$$

$$\text{MEM} = B \cdot C \cdot S_o^2$$

★ ReLU

$$\text{FLOPS} = B \cdot C \cdot S_o^2 \quad \text{т.к. 1 сравн. на эл.}$$

$$\text{MEM} = 0 \quad (\text{т.к. inplace=True, не выделяем})$$

★ Adaptive AVG Pool

$$\text{Flops} = B \cdot C \cdot S_o^2 \quad \text{просто сумма взвеш.$$

$$\text{MEM} = B \cdot C$$


★ Linear

$$\text{Flops} = B \cdot C_i \cdot C_o$$

$$\text{MEM} = B \cdot C_o + C_i \cdot C_o$$

Latency будем определять как скорость масс
как GPU перемещаем данные (V_b) на конкретное извл.
данные N_b (байт и аккумуляции)

V_b - это по сути масс rate throughput



$$V_b(N_b) = \min(V_m, V_0 + N_b \cdot \frac{V_m - V_0}{N_m})$$

В предполож. случ. Memory Bound

V_m, V_0, N_m - параметры

$$lat(N_b) = V_b(N_b) \cdot N_b$$

Energy по сути ~~определяется~~ ^{выражается} скоростью изменения
данных и временем её перемещения

$$energy(N_b) = \Theta(lat(N_b) \cdot V_b(N_b)) \approx V_b^2(N_b) \cdot N_b$$

Получаем мы же конст. параметры.